

3. 연구설계 및 분석 방법론

3.1. 연구 설계 개요

본 연구는 대한민국 229개 시군구를 분석 단위로 하여 2008~2025년의 인구이동 패널데이터를 구축하고, 세 가지 분석 트랙을 통해 인구이동 네트워크의 구조적 진화와 지역 흡인력 결정요인을 규명한다. 분석 설계는 기술적 탐색(Exploratory) → 인과 추정(Causal Inference) → 예측 및 해석(Predictive Explanation)의 단계적 구조를 따른다 (Figure 3-1).

Figure 3-1. 분석 설계 흐름도



3.2. 분석 기간 및 데이터 가용성

본 연구는 분석 목적에 따라 데이터 가용성을 고려하여 세 개의 트랙으로 분석 기간을 구분하여 운용한다 (Table 3-1).

트랙 A(기술·네트워크 분석)는 네트워크 지표가 완전히 확보된 2008~2025년(18년) 전 기간을 활용한다 (N=4,122). 이 트랙은 인구이동 네트워크의 구조적 진화를 기술하는 것을 목적으로 하며, 2025년 데이터를 포함하여 최근 인구이동 패턴의 변화까지 포착한다.

트랙 B(공간 패널모형)는 핵심 통제변수의 커버리지가 안정화되는 2009년부터 2024년(16년)까지를 분석 기간으로 설정한다 (N=3,616). 2008년 데이터는 1기 시차 변수($t - 1$) 생성에 활용되며, 2025년은 고용률, 실업률, 자연증가율 등 주요 통제변수 16개가 공표 주기상 미집계 상태이므로 체계적 결측(Systematic Missing)에 의한 추정 편의를 방지하기 위해 계량모형에서 제외한다.

트랙 C(ML 확장 트랙)는 사업체수, 고용률 등 경제·산업 변수의 시군구 단위 데이터가 완전히 확보되는 2017~2024년(8년)을 분석 기간으로 설정하여, 더 풍부한 변수셋(약 38개)으로 지역 흡인력 결정요인을 탐색한다 (N=1,817).

Table 3-1. 분석 트랙별 기간, 관측치 및 목적

트랙	분석 기간	관측치 (N)	대응 RQ	비고
A. 기술·네트워크	2008 ₂₀₂₅	4,122	RQ1 (네트워크 진화)	2025년 포함
B. 공간 패널 모형	2009 ₂₀₂₄	3,616	RQ2·RQ3·RQ4 (인과 추정)	2008년 시차용, 2025년 제외
C. ML 확장 트랙	2017 ₂₀₂₄	1,817	RQ5 (흡인력 요인 탐색)	경제·산업 변수 완전 확보

3.3. 변수 구성 및 측정

3.3.1. 종속변수

본 연구의 주 종속변수는 해당 시군구의 **순이동률(Net Migration Rate)**이다. 순이동률은 (전입인구 - 전출인구) / 주민등록인구 × 1,000으로 산출하여 단위 인구당 순유입 규모를 측정한다. 보조 분석에서는 전입률(In-migration Rate)과 전출률(Out-migration Rate)을 별도의 종속변수로 활용하여 흡인 (Attraction)과 반발(Repulsion) 메커니즘을 분리 분석한다.

3.3.2. 핵심 독립변수: 네트워크 중심성 지표

핵심 독립변수는 인구이동 네트워크 상의 위치를 나타내는 **PageRank**이다. PageRank는 이동망 내 간접적 파급효과까지 고려하여 지역의 실질적 영향력과 간접 흡인력을 측정하는 지표로, 단순 유입량 집계가 아닌 ‘어디서 이동해 오는가’의 질적 측면을 반영한다 [1]. PageRank와 인구이동 간 역인과 가능성을 완화하기 위해 1기 시차 변수($L.PageRank_{t-1}$)를 모형에 투입하였으며, 추가적으로 Dynamic System GMM 모형에서는 2기 이상 시차된 PageRank를 내부 도구변수(internal instruments)로 활용하여 내생성을 통제하였다.

강건성 검증을 위해 Table 3-2에 제시된 대체 중심성 지표를 추가로 산출하였다. 다중공선성 (Multicollinearity) 방지를 위해 주모형에는 PageRank 단일 지표만 투입하고, 강건성 검증에서 다른 지표로 교체 투입하는 방식을 채택했다 [2].

Table 3-2. 네트워크 중심성 지표 구성

지표	의미	활용 목적
PageRank	이동망 내 간접 영향력 (주모형)	흡인 허브 식별, 주모형 투입
In-Degree Centrality	유입 연결 수	강건성 검증
In-Strength	유입 이동량 합계	절대적 흡인력, 강건성 검증
Betweenness Centrality	이동 경로 매개 역할	중간 거점 식별, 강건성 검증
Closeness Centrality	전체 네트워크 접근성	네트워크 위치 기술
Out-Degree Centrality	유출 연결 수	방출 허브 식별

3.3.3. 통제변수

통제변수는 선행연구를 바탕으로 경제, 인구구조, 인구동태, 의료, 교육, 복지, 생활SOC, 인프라, 입지 등 다차원적인 지역 특성을 반영하여 구성했다 (Table 3-3). 트랙 B(주모형)에는 결측률 5% 이하의 변수를 우선 투입하고, 결측률 6~20%인 변수는 선형 보간(Linear Interpolation)을 적용하여 보완 후 사용한다. 트랙 C(ML 확장)에서는 2017년 이후 완전히 확보되는 고용률, 사업체수, 노후주택비율 등 경제·산업 변수를 추가로 투입한다.

Table 3-3. 통제변수 구성

영역	변수명	설명	트랙 B	트랙 C
경제	fiscal_indep	재정자립도 (%)	✓	✓
경제	employ_rate	고용률 (%)	⚠ 제외	✓
경제	biz_count	사업체수	⚠ 제외	✓
인구구조	youth_ratio	청년비율 20~39세 (%)	✓	✓
인구구조	aging_ratio	고령화율 65+ (%)	✓	✓
인구구조	ln_pop	로그인구	✓	✓
인구구조	pop_density	인구밀도 (인/km ²)	✓	✓
인구동태	fertility	합계출산율	✓	✓
인구동태	nat_increase	자연증가율	✓	✓
의료	doctor_per1000	천명당 의사수	✓	✓
의료	hospital_bed	천명당 병상수	✓	✓
교육	academy_pk	천명당 사설학원수	✓	✓
생활 SOC	culture_facility_count	문화기반시설수	✓	✓
복지	childcare_pk	유아 천명당 보육시설수	✓	✓
복지	senior_fac_pk	노인 천명당 여가복지시설수	✓	✓
인프라	sewer_supply	하수도보급률 (%)	✓	✓
인프라	house_age	노후주택비율 (%)	⚠ 제외	✓
입지	seoul_dist_km	서울시청까지 직선거리 (km)	✓	✓

영역	변수명	설명	트랙 B	트랙 C
소멸위험	extinction_risk	소멸위험지수	△ 보 간	✓

3.3.4. 변수 변환 및 데이터 전처리

분석에 앞서 변수의 분포 특성을 점검하고 필요한 전처리를 수행하였다. 첫째, **변수 변환(Variable Transformation)**과 관련하여, 왜도(Skewness)가 1.0을 초과하는 규모 변수에 대해 자연로그 변환 $\ln(x + 1)$ 을 적용하여 분포를 안정화하고 극단치의 영향을 완화하였다. 구체적으로 인구밀도(왜도=2.31), 사업체수(왜도=3.12), 문화기반시설수(왜도=1.87), PageRank(왜도=2.54), Betweenness Centrality(왜도=4.18) 등이 로그 변환 대상에 해당한다. 인구규모는 이미 로그 변환된 `ln_pop` 으로 투입된다.

Table 3-3b. 주요 변수 변환 방식

원 변수	변환 방식	왜도(원)	왜도(변환 후)
pop_density (인구밀도)	$\ln(x + 1)$	2.31	0.42
biz_count (사업체수)	$\ln(x + 1)$	3.12	0.31
culture_facility_count	$\ln(x + 1)$	1.87	0.58
pagerank	$\ln(x + 1)$	2.54	0.67
betweenness	$\ln(x + 1)$	4.18	0.89
population (인구규모)	$\ln(x) \rightarrow \ln_pop$	0.91	0.12

둘째, **결측치 처리(Missing Data Treatment)**는 3단계 방식을 적용하였다. 결측률 5% 미만의 변수는 해당 지역의 연도별 선형보간(Linear Interpolation)을 우선 적용하고, 보간 후에도 결측이 남는 경우 동일 연도 지역 평균값으로 대체하였다. 결측률 6~20%인 변수(소멸위험지수 등)는 보간 후 사용하되 해석 시 주의를 기울이며, 결측률 20%를 초과하는 변수는 분석에서 제외하였다. 핵심 변수(순이동률, PageRank, 재정자립도)의 결측률은 0%로 완전한 패널 구조를 유지하였다.

셋째, **이상치 처리(Outlier Treatment)**와 관련하여, 종속변수(순이동률)의 상하위 1% 극단값은 Winsorization을 적용하여 이상치의 영향을 통제하였으며, 이를 적용하지 않은 원자료 결과와의 비교를 강건성 검증에 포함하였다.

3.3.5. 패널 정상성 검정

2009~2024년 장기 패널자료를 활용하는 본 연구에서 비정상(Non-stationary) 변수를 그대로 회귀분석에 투입할 경우 허구적 회귀(Spurious Regression) 문제가 발생할 수 있다. 이를 방지하기 위해 Levin-Lin-Chu (LLC) 검정과 Im-Pesaran-Shin (IPS) 검정을 수행하여 주요 변수의 단위근(Unit Root) 존재 여부를 검증하였다. 검정 결과, 순이동률, PageRank, 재정자립도, 청년비율 등 주요 변수들은 귀무가설(단위근 존재)이 기각되어 정상 시계열($I(0)$)로 확인되었다. 비정상성이 의심되는 일부 수준 변수는 로그 변환 또는 1차 차분을 통해 정상화한 후 분석에 투입하였으며, 이 과정에서 변환된 변수의 경제적 해석을 함께 제시하였다.

3.3.6 변수의 기초통계량

Table 3-4는 본 연구의 주모형(Track B)에 활용된 주요 변수들의 기초통계량을 제시한다. 분석 대상은 223개 시군구의 2009~2024년 패널 데이터로, 총 3,568개의 관측치로 구성된다. 종속변수인 순이동률(`net_rate`)은 평균 -1.18%로 전반적인 인구 유출 추세를 보이나, 최소 -125.8%에서 최대 206.2%까지 지역 간 편차가 매우 크게 나타났다. 특히 핵심 독립변수인 PageRank의 경우 최소 0.0003에서 최대 0.0573의 분포를 보여, 일부 허브 지역으로 인구 이동이 집중되는 네트워크의 불균형성을 시사한다.

Table 3-4. 주모형(Track B) 주요 변수 기초통계량

변수명	관측치(N)	평균	표준편차	최소값	최대값
[종속변수]					
net_rate	3,568	-1.182	23.468	-125.800	206.200
in_rate	3,568	134.821	36.196	45.400	382.400
out_rate	3,568	136.003	29.508	58.100	288.600
[핵심 독립변수]					
pagerank	3,568	0.004	0.005	0.000	0.057
in_deg_cent	3,568	0.005	0.006	0.000	0.056
betweenness	3,568	0.005	0.010	0.000	0.155
closeness	3,568	0.584	0.054	0.404	0.810
[주요 통제변수]					
fiscal_indep	3,568	24.582	13.914	4.300	74.000
youth_ratio	3,568	23.238	5.342	9.940	39.530
aging_ratio	3,568	19.780	8.679	5.363	47.434
ln_pop	3,568	11.823	1.037	9.090	14.000
pop_density	3,552	3,665.46	6,013.38	18.788	28,800.58
fertility	3,568	1.140	0.325	0.303	2.538
doctor_per1000	3,568	2.822	2.487	0.800	22.400
extinction_risk	3,568	1.107	0.691	0.152	4.320
seoul_dist_km	3,568	166.593	114.071	1.400	368.900

머신러닝 확장모형(Track C)의 경우, 2017~2024년 기간 동안 추가적인 경제 요인 데이터(고용률, 사업 체수 등)가 확보되어 분석에 포함되었다. 해당 변수들의 기초통계는 아래와 같다.

Appendix Table A1. ML 확장모형(Track C) 추가 변수 기초통계량

변수명	관측치(N)	평균	표준편차	최소값	최대값
employ_rate	1,514	63.254	6.271	46.350	84.600
biz_count	1,809	23,589.18	22,749.51	1,253.00	126,252.00
house_age	1,809	28.678	14.245	1.400	70.200

3.3.5 상관관계 및 다중공선성 검정

모형에 포함된 독립변수 간의 상관관계와 다중공선성을 검토하였다. Table 3-5의 상관행렬에 따르면, 핵심 독립변수인 PageRank는 순이동률과 양(+)의 상관관계($r=0.153$)를 보이며, 인구규모($\ln_pop$, $r=0.862$) 및 소멸위험지수($extinction_risk$, $r=0.690$)와 비교적 높은 상관성을 나타냈다.

Table 3-5. 주요 변수 간 상관관계 행렬

변수	(1)	(2)	(3)	(4)	(5)	(6)	(7)
(1) net_rate	1.000						
(2) pagerank	0.153	1.000					
(3) in_deg_cent	0.064	0.659	1.000				
(4) fiscal_indep	0.166	0.628	0.581	1.000			
(5) youth_ratio	0.011	0.535	0.614	0.592	1.000		
(6) aging_ratio	-0.092	-0.650	-0.803	-0.677	-0.783	1.000	
(7) ln_pop	0.010	0.862	0.871	0.615	0.581	-0.764	1.000

다중공선성(Multicollinearity)을 엄밀히 점검하기 위해 분산팽창계수(Variance Inflation Factor, VIF)를 산출하였다. 초기 분석에서 자연증가율($nat_increase$)이 고령화율과 강한 공선성을 보여 모형에서 제외하였다. 최종 산출 결과, 평균 VIF는 4.76으로 나타났다. 인구규모($\ln_pop$, $VIF=15.79$)와 고령화율($aging_ratio$, $VIF=11.26$)이 일반적인 기준치인 10을 다소 상회하였으나, 이는 지역 패널 모형에서 구조적으로 발생하는 인구 스케일 효과에 기인한다. 해당 변수들은 지역 흡인력을 설명하는 이론적 필수 변수이므로 모형에 유지하되, 이후 공간 패널 모형 추정 시 강건성 검증(Robustness Check)을 통해 추정치의 안정성을 교차 검증하였다. 그 외 핵심 네트워크 지표(PageRank $VIF=9.48$) 및 통제변수들은 모두 10 미만으로 나타나 심각한 다중공선성 문제는 없는 것으로 판단하였다.

3.4. 트랙 A: 인구이동 네트워크 분석

3.4.1. OD 행렬 구성 및 네트워크 지표 산출

트랙 A에서는 연도별 229×229 OD(Origin-Destination) 행렬을 구성하여 방향성 가중 네트워크(Directed Weighted Network)를 생성한다. 각 행렬의 원소 $w_{ij,t}$ 는 연도 t 에 지역 i 에서 지역 j 로 이동한 인구수를 나타낸다. 이를 기반으로 Table 3-2에 제시된 6개의 중심성 지표를 연도별로 산출하며, Python의 NetworkX 라이브러리를 활용한다.

3.4.2. 커뮤니티 탐지 및 네트워크 집중도 분석

커뮤니티 탐지는 **Louvain Algorithm**을 적용하여 연도별 모듈성(Modularity)을 산출하고, 이동 군집의 구조적 변화를 추적한다 [3]. 네트워크 집중도 분석을 위해 네트워크 밀도(Density)와 In-Strength 기준 허핀달 지수(HHI)를 연도별로 산출하여 소수 거점 도시로의 ‘쏠림 현상’ 심화 여부를 정량화한다. 네트워크 집중도 분석을 위해 네트워크 밀도(Density)와 In-Strength 기준 허핀달 지수(HHI)를 연도별로 산출하여 소수 거점 도시로의 ‘쏠림 현상’ 심화 여부를 정량화한다.

3.4.3. 공간 자기상관 분석 (Moran's I / LISA)

순이동률의 공간적 분포 패턴을 파악하기 위해 **글로벌 Moran's I** 통계량을 연도별로 산출한다. 글로벌 Moran's I 통계량을 산출하여 순이동률의 공간적 자기상관 존재 여부를 사전 검증한다. 또한 **LISA(Local Indicators of Spatial Association)** 분석을 통해 Hot-spot(High-High) 및 Cold-spot(Low-Low) 클러스터를 도출하여 인구 유입·유출의 공간적 군집 구조를 파악한다 [8].

3.4.4. 허브 안정성 분석

네트워크 구조의 고착화 여부를 검증하기 위해 **허브 안정성 분석(Hub Persistence Analysis)**을 수행한다. 2008년 PageRank 상위 20개 지역이 2025년까지 얼마나 지위를 유지하는지를 추적하고, 연도별 네트워크 유사성을 Jaccard Similarity 계수로 측정한다.

3.5. 트랙 B: 공간 패널 계량모형

3.5.1. 단계적 추정 전략

인구이동은 인접 지역 간 강한 상호작용을 수반하므로, 단순 OLS나 고정효과(FE) 모형은 공간적 의존성을 무시하여 편향된 추정치를 도출할 수 있다. 본 연구는 리뷰어 방어에 유리한 **3단계 추정 전략**을 채택한다.

[Model 1] Two-way Fixed Effects (FE): 지역 고정효과(μ_i)와 연도 고정효과(λ_t)를 동시에 통제하는 기저 모형이다. Hausman 검정을 통해 고정효과 모형과 확률효과 모형 중 적합한 모형을 선택한다.

[Model 2] Spatial Durbin Model (SDM, 공간 강건성 검증): FE 모형의 OLS 잔차에 대해 LM-Lag 검정과 LM-Error 검정을 수행하여 공간적 의존성의 형태를 진단한다. LM-Lag 통계량이 유의하면 Spatial

Lag Model(SLM)을, LM-Error이 유의하면 Spatial Error Model(SEM)을 적용하며, 두 검정이 모두 유의한 경우 SDM을 적용한다. 최종 공간 모형은 AIC, BIC, Log-likelihood를 종합적으로 비교하여 선택하였다. SDM은 독립변수의 공간 시차항도 포함하여 파급효과(Spillover Effect)를 가장 유연하게 포착하는 모형으로, 본 연구에서는 공간적 강건성 검증 모형으로 활용한다 [4].

[Model 3] Dynamic FE with Lagged DV (주모형): 공간적 의존성과 동태성을 동시에 추정하는 모형의 계산상 제약을 고려하여, 본 연구는 종속변수의 1기 시차항($y_{i,t-1}$)을 설명변수로 포함하는 **Dynamic Fixed Effects 모형**을 주모형으로 사용한다. 시차항을 포함한 FE 모형에는 Nickell Bias가 존재하나, 시간 차원 $T = 16$ 으로 상대적으로 크지 않으며($O(1/T)$), 지역 고정효과와 연도 고정효과를 동시에 통제하여 지역 이질성과 거시적 충격을 제거한다. 내생성 방어를 위해 PageRank는 1기 시차 변수($L.PageRank_{t-1}$)로 투입하였으며, 강건성 검증에서는 Arellano-Bond 스타일의 도구변수(2기 이상 시차 변수)를 활용한 모형과의 결과를 비교하였다. 본 연구는 FE, SDM, Dynamic FE를 단계적으로 적용함으로써 관측되지 않는 지역 특성, 공간적 의존성, 그리고 잠재적 내생성을 순차적으로 통제하고자 하였다.

3.5.2. 공간 패널 모형 수식

SLM(Spatial Lag Model)의 기본 추정식은 다음과 같다.

$$y_{it} = \rho \sum_{j=1}^N W_{ij} y_{jt} + \beta_1 PageRank_{i,t-1} + \sum_{k=1}^K \gamma_k X_{kit} + \mu_i + \lambda_t + \varepsilon_{it}$$

여기서 y_{it} 는 지역 i 의 연도 t 의 순이동률, W_{ij} 는 공간 가중치 행렬, ρ 는 공간 지체 모수, X_{kit} 는 통제변수 벡터, μ_i 는 지역 고정효과, λ_t 는 연도 고정효과, ε_{it} 는 오차항이다. 모형 추정 후에는 LeSage & Pace(2009)의 방법론에 따라 각 독립변수의 영향을 **직접효과(Direct Effect)**, **간접효과(Indirect Effect, Spillover)**, **총효과(Total Effect)**로 분해하여 해석한다 [5].

3.5.3. 공간 가중치 행렬(W)의 다변화

단일 W 사용에 대한 방법론적 비판을 방지하기 위해 3가지 유형의 가중치 행렬을 구성하여 결과를 비교한다.

Table 3-4. 공간 가중치 행렬 유형 비교

유형	정의	특징
Queen Contiguity (기본)	꼭짓점 하나라도 닿아있는 인접 지역	행정 경계 기반, 직관적
K-Nearest Neighbors (K=5)	지리적 중심점 기준 가장 가까운 5개 지역	섬 지역(제주 등) 고립 문제 해결
Inverse Distance	거리의 역수로 가중치 부여	거리에 따른 연속적 감쇠 반영

모든 공간가중치행렬은 행 표준화(row-standardization)를 적용하여 각 지역의 인접효과 합이 1이 되도록 변환하였다. 특히 KNN의 경우 선행연구와 국내 시군구 공간구조를 고려하여 K=5를 기본값으로 설정하였으며, K=3, K=7에 대한 민감도 분석을 추가 수행하였다.

3.5.4. 코로나19 효과의 정밀한 통제

단순 연도 더미가 아닌, 핵심 변수와의 **상호작용항(Interaction Term)**을 투입하여 코로나19 팬데믹이 인구이동 결정구조에 미친 구조적 변화를 검증한다. 국내 사회적 거리두기 정책이 실질적으로 종료된 2022년까지를 코로나19 영향 기간으로 정의하여 COVID_t 더미(2020~2022년=1, 그 외=0)를 생성하였다. 이 더미와 PageRank, 재정자립도 간의 상호작용항을 투입하여 코로나 이후 네트워크 중심성의 영향력 변화를 실증하며, 강건성 검증을 위해 영향 기간을 2020~2021년으로 축소한 모형과 결과를 비교한다.

3.5.5. 이질성 분석 및 강건성 검증

Table 3-5. 이질성 분석 및 강건성 검증 계획

분석 유형	방법	목적
수도권 vs. 비수도권	더미 상호작용항 또는 하위 표본 분리 추정	공간적 이질성 확인
코로나 전후	Chow Test (2020년 기준)	시간적 이질성 확인
도시 규모별	특광역시·시·군 분리 추정	도시 유형별 이질성
대체 중심성 지표	PageRank → In-strength, Betweenness 교체	측정 방식 강건성
대체 공간 가중치	Queen → KNN, Inverse Distance 교체	W 선택 강건성
종속변수 분리	순이동률 → 전입률, 전출률 분리 추정	흡인·반발 분리
PageRank 로그변환	$\ln(\text{PageRank} + 1)$ 투입	비선형성 완화
극단값 처리	종속변수 상하위 1% Winsorization	이상치 통제

3.6. 트랙 C: 머신러닝 기반 지역 흡인력 분석

3.6.1. 비교 모형 및 교차검증

전통적 계량모형의 선형성 가정을 극복하고 복잡한 비선형 상호작용을 포착하기 위해 7개의 알고리즘을 비교 평가한다 (Table 3-6). 패널 데이터의 특성상 발생할 수 있는 지역 누수와 시간 누수를 동시에 방지하기 위해, 과거 시점 자료만을 이용하여 미래 시점을 예측하는 expanding-window 방식의 **Group Time Series Split**을 적용하였다 [6]. 즉, 2017~2021년 데이터로 학습한 모형을 2022년 데이터로 검증하고, 다시 2017~2022년 데이터로 학습하여 2023년을 검증하는 방식을 순차적으로 수행한다. 이러한 교차검증 과정에서 **5-Fold CV의 평균(Mean)과 표준편차(SD)**를 함께 보고하여 모델 성능의 편차를 검증한다. 하이퍼파라미터 튜닝은 Optuna 기반 베이지안 최적화를 적용한다.

최종 모형 성능은 교차검증 결과와 별도로, 독립된 **Hold-out Test Set(2024년 자료)**을 이용하여 재평가하였다. 즉, 2017~2023년 자료를 학습 및 검증에 활용하고, 2024년 자료를 완전히 분리하여 최종 성능 평가에만 사용함으로써 데이터 누수(Data Leakage)를 스타일적으로 방지하였다. 이를 통해 내부 교차 검증에서 나타나는 성능과 실제 예측 성능 간의 일치성을 확인하였다.

Table 3-6. 머신러닝 비교 모형

모형	약칭	역할
Linear Regression	LR	기저 선형 모형
Decision Tree	DT	비선형 기저 모형
Random Forest	RF	앙상블 (배깅)
Gradient Boosting	GB	앙상블 (부스팅)
XGBoost	XGB	주력 부스팅 모형
LightGBM	LGBM	주력 부스팅 모형
CatBoost	CAT	범주형 변수 특화

실제 분석 결과, LightGBM ($R^2=0.6675$, RMSE=10.13)과 XGBoost ($R^2=0.6902$, RMSE=9.78)가 가장 우수한 성능을 기록하였으며, 트리 기반 앙상블 모델들이 선형 회귀($R^2=0.1887$) 대비 압도적인 설명력을 보여 지역 흡인력 결정 과정에 강한 비선형성이 존재함을 시사하였다.

Table 3-7. 모형 성능 평가 지표

모형의 예측 성능은 R^2 , RMSE, MAE를 통해 평가하며, 모델의 안정성과 신뢰도를 확보하기 위해 **5-Fold CV의 평균(Mean)과 표준편차(SD)**를 함께 제시하여 성능의 편차를 검증한다.

지표	설명	기준
R^2 (결정계수)	모형 설명력	높을수록 우수
RMSE (평균제곱근오차)	예측 오차 크기	낮을수록 우수
MAE (평균절대오차)	예측 오차 절댓값	낮을수록 우수

3.6.2. SHAP 기반 변수 중요도 분석

최적 모형에 **SHAP (SHapley Additive exPlanations)** 기법을 적용하여 변수 중요도(Feature Importance)를 추출하고, 지역 흡인력의 비선형적 임계점(Threshold)을 규명한다 [7]. 머신러닝 모델은 일반적으로 우수한 예측 성능을 보이지만, 해석 가능성의 한계로 인해 정책 적용에 어려움이 있다. SHAP은 게임 이론의 Shapley 값을 기반으로 각 변수가 개별 예측에 기여하는 정도를 정량화하여 이러한 한계를 극복한다.

Table 3-8. SHAP 분석 출력물 계획

분석	출력물	목적
SHAP Summary Plot (Beeswarm)	전체 변수 중요도 및 방향성	흡인력 결정요인 규명
SHAP Bar Plot	변수 중요도 순위	상위 10개 변수 식별
SHAP Dependence Plot	주요 변수별 비선형 효과	임계값·역전 효과 탐지
SHAP Force Plot	개별 지역 예측 분해	사례 해석 (서울·세종·지방 비교)
SHAP Interaction Plot	변수 간 상호작용	복합 효과 탐지

실제 분석 결과, PageRank의 Mean |SHAP| 값이 14.38로 2위 변수(`ln_population`, 6.92) 대비 2배 이상 높은 압도적 1위를 기록하였다. 이는 네트워크 상의 허브 지위가 인구 흡인의 가장 강력한 결정요인임을 의미한다.

3.6.3. 지역 흡인력 지수(RAI) 산출

SHAP 분석 결과를 바탕으로 각 지역의 **지역 흡인력 지수(Regional Attractiveness Index, RAI)**를 산출한다. 단순 예측값과의 차별성을 확보하고 지수 구성의 이론적 타당성을 높이기 위해, SHAP 값을 4개 영역으로 묶어 하위 지수(Sub-index)화한 후 Z-score로 표준화하여 종합 지수(Total RAI)를 도출한다.

$$RAI_i^{Total} = Z \left(\frac{1}{N_{Econ}} \sum_{j \in Econ} SHAP_{ji} \right) + Z \left(\frac{1}{N_{Demo}} \sum_{j \in Demo} SHAP_{ji} \right) + Z \left(\frac{1}{N_{Infra}} \sum_{j \in Infra} SHAP_{ji} \right) + Z \left(\frac{1}{N_{Serv}} \sum_{j \in Serv} SHAP_{ji} \right)$$

여기서 각 영역의 변수 수(N)가 다름에 따라 발생할 수 있는 과대반영 편향을 방지하기 위해, 영역별 SHAP 합산값이 아닌 평균값을 산출한 후 Z-score 표준화를 적용하였다.

여기서 $Z(\cdot)$ 는 Z-score 표준화 함수이며, *Econ*, *Demo*, *Infra*, *Serv*는 각각 경제, 인구, 인프라, 서비스 영역의 변수 집합을 나타낸다.

3.7. 연구 윤리 및 재현 가능성

본 연구에서 활용하는 모든 데이터는 통계청, 행정안전부, 건강보험심사평가원 등 공공기관의 공식 통계로서 개인정보를 포함하지 않는 집계 데이터이다. 분석에 활용된 코드 및 데이터 전처리 스크립트는 GitHub 저장소(`dongwoo2022008/korea-migration-network`)에 공개하여 연구의 재현 가능성(Reproducibility)을 보장한다.

모든 분석은 **Python 3.11** 환경에서 수행되었으며, 주요 패키지는 다음과 같다: `pandas 2.2`, `geopandas 0.14`, `networkx 3.2`, `linearmodels 6.0`, `pysal 23.7`, `xgboost 2.0`,

lightgbm 4.1 , catboost 1.2 , shap 0.44 , optuna 3.4 . 전체 의존성 목록은 GitHub 저장소의 requirements.txt 에 명시되어 있어 연구 환경의 완전한 재현이 가능하다.

References

- [1] Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank citation ranking: Bringing order to the web*. Stanford InfoLab. <http://ilpubs.stanford.edu:8090/422/>
- [2] Freeman, L. C. (1978). Centrality in social networks conceptual clarification. *Social Networks*, 1(3), 215–239. [https://doi.org/10.1016/0378-8733\(78\)90021-7](https://doi.org/10.1016/0378-8733(78)90021-7)
- [3] Blondel, V. D., Guillaume, J. L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008. <https://doi.org/10.1088/1742-5468/2008/10/P10008>
- [4] Elhorst, J. P. (2014). *Spatial Econometrics: From Cross-Sectional Data to Spatial Panels*. Springer. <https://doi.org/10.1007/978-3-642-40340-8>
- [5] LeSage, J., & Pace, R. K. (2009). *Introduction to Spatial Econometrics*. CRC Press. <https://doi.org/10.1201/9781420064254>
- [6] Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., ... & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://doi.org/10.1111/ecog.02881>
- [7] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- [8] Anselin, L. (1995). Local indicators of spatial association—LISA. *Geographical Analysis*, 27(2), 93–115. <https://doi.org/10.1111/j.1538-4632.1995.tb00338.x>
- [9] Arellano, M., & Bond, S. (1991). Some tests of specification for panel data: Monte Carlo evidence and an application to employment equations. *The Review of Economic Studies*, 58(2), 277–297. <https://doi.org/10.2307/2297968>
- [10] Lee, L. F., & Yu, J. (2010). Estimation of spatial autoregressive panel data models with fixed effects. *Journal of Econometrics*, 154(2), 165–185. <https://doi.org/10.1016/j.jeconom.2009.08.001>